

Seminarska naloga iz Statistike

Dejan Perić

4. januar 2022

Prva naloga

a)

Izmed 43886 družin izberemo vzorec družin velikosti 200. Vzorce bomo pridobivali s pomočjo *sample* iz knjižnice *random*. Za cenilko povprečnega števila otrok bomo vzeli cenilko

$$\hat{\mu} = \frac{1}{200} \sum_{i=1}^{200} X_i$$

Dobimo oceno, da je povprečno število otrok v Kibergradu enako 0.8400.

b)

Za cenilko standardne napake bomo vzeli cenilko iz predavanj. Ta je enaka

$$\widehat{SE}_+^2 = \frac{N-n}{N-1} \cdot \frac{\hat{\sigma}_+^2}{n} ,$$

pri čemer je $\hat{\sigma}_+^2$ enaka

$$\hat{\sigma}_+^2 = \frac{N-1}{N} \cdot \frac{1}{n-1} \sum_{i=1}^n (X_i - \bar{X})^2 .$$

$$\widehat{SE}_+^2 = \frac{N-n}{N} \cdot \frac{1}{n \cdot (n-1)} \sum_{i=1}^n (X_i - \bar{X})^2$$

Pri nas je $N = 43886$ in $n = 200$, torej je

$$\widehat{SE}_+^2 = \frac{43686}{43886} \cdot \frac{1}{200 \cdot 199} \sum_{i=1}^{200} (X_i - \bar{X})^2 .$$

Izračunamo, da je standardna napaka enaka 0.071584. Sedaj s pomočjo studentove porazdelitve izračunajmo eksakten 95% interval zaupanja. Iz predavanj vemo, da je ta oblike

$$\mu \in (\hat{\mu} - \widehat{SE}_+ \cdot F_{Student(n-1)}^{-1}(1 - \frac{\alpha}{2}), \hat{\mu} + \widehat{SE}_+ \cdot F_{Student(n-1)}^{-1}(1 - \frac{\alpha}{2})) .$$

Oceni za povprečno število otrok ($\hat{\mu}$) in standardno napako (\widehat{SE}_+) že imamo. Stopnja tveganja je enaka $\alpha = 0.05$. S pomočjo knjižnice *scipy.stats* izračunamo, da je

$$F_{Student(n-1)}^{-1}(1 - \frac{0.05}{2}) = F_{Student(n-1)}^{-1}(0.975) = 1.9720$$

Interval zaupanja je torej enak (0.69884, 0.98116).

c)

Za cenilko povprečja celotne populacije bomo vzeli isto kot smo za oceno populacijskega povprečja pri vzorcu.

$$\mu = \frac{1}{43886} \sum_{i=1}^{200} X_i = 0.94793$$

Vzorčno povprečje primerjamo z izračunanim populacijskim povprečjem. Relativna napaka vzorčnega povprečja je 11.39%.

Iz vseh podatkov družin lahko izračunamo varianco števila otrok družin, s pomočjo katere bomo lahko ocenili, kakšna je prava standardna napaka za vzorec velikosti 200. Ker imamo podatke celotne populacije, za cenilko variance vzamemo

$$\sigma^2 = \frac{1}{n} \sum_{i=1}^{43886} (X_i - \bar{X})^2 = 1.3391$$

Za cenilko prave standardne napake vzamemo cenilko, najdeno v knjigi John Rice: *Mathematical Statistics & Data Analysis*, str. 202-220.

$$SE^2 = \frac{\sigma^2}{n} \cdot \left(\frac{N-n}{N-1} \right) = \frac{\sigma^2}{200} \cdot \frac{43686}{43885}$$

Dobimo, da je prava standardna napaka ocenjena z $SE = 0.081640$. Relativna napaka vzorčne standardne napake je torej 12.32%.


Opazimo, da je

$$\mu = 0.94793 \in (0.69884, 0.98116),$$

torej interval zaupanja iz prejšnje točke pokrije populacijsko povprečje.

d)


Vzemimo še 99 vzorcev populacije velikosti 200. Določimo 95% intervale zaupanja. Glede na to, da imamo skupaj 100 vzorcev, pričakujemo, da bo približno 95 intervalov zaupanja pokrilo populacijsko povprečje ($\mu = 0.94793$). Vse skupaj ponazorimo z grafom.



Ugotovimo, da 95 intervalov pokrije populacijsko povprečje, kar je tako, kot smo pričakovali.

e)


Za teh 99 vzorcev izračunamo še standardni odklon za vsakega posebej. Za cenilko standardnega odklona vzamemo isto, kot smo jo vzeli za standardno napako v prvem vzorcu; standardni odklon in standardna napaka sta namreč ista. Skupaj s pravo standardno napako rezultate prikažemo z grafom.



Največji vzorčni standardni odklon izmed stotih vzorcev je enak 0.094196, najmanjši pa 0.070726; standardni odkloni se torej nahajajo na območju širine 0.023469. Povprečje dobljenih standardnih odklonov je 0.080816, relativna napaka od prave standardne napake pa je enaka 1.010%, kar je po mojem mnenju kar dober približek pravi standardni napaki.


f)

Sedaj vzamemo 100 vzorcev populacije velikosti 400. Za vsak vzorec izračunamo interval zaupanja in standardni odklon. Ker imamo 95% interval zaupanja, spet pričakujemo, da bo približno 95 intervalov pokrilo populacijsko povprečje.



Sedaj imamo 96 takih intervalov zaupanja, ki pokrijejo populacijsko povprečje, kar je tudi tako, kot smo pričakovali. Opazimo tudi, da so velikosti intervalov sedaj manjše kot pri vzorcih velikosti 200.

Poglejmo si še graf z ocenjenimi standardnimi odkloni.



Največji ocenjeni standardni odklon je velikosti 0.063122, najmanjši pa 0.050939. Vidimo, da sta ti dve vrednosti še kar manjši od tistih dveh, izračunanih za vzorce velikosti 200. Razlika se opazi tudi pri širini območja ocenjenih standardnih odklonov; to je velikosti 0.012183, kar je za dvakrat manjše od prej izračunane širine. Povprečje dobljenih standardnih odklonov je 0.057846, relativna napaka od prave standardne napake pa je enaka 0.4330%. Dobimo še boljši približek prave standardne napake kot pri vzorcih velikosti 200.

Druga naloga

a)

V datoteki *TempPulz* se nahajajo podatki o temperaturi 65 moških in 65 žensk v Fahrenheitovih stopinjah (F). Najprej ocenimo povprečje temperature tako moških kot žensk. Za cenilko vzamemo cenilko, ki jo ponavadi uporabimo za ocenjevanja povprečja:

$$\hat{\mu}_1 = \frac{1}{65} \sum_{i=1}^{65} X_i, \quad \hat{\mu}_2 = \frac{1}{65} \sum_{i=1}^{65} Y_i$$

Povprečje telesne temperature moških ocenimo z $\hat{\mu}_1 = 98.10462^\circ\text{F} = 36.72479^\circ\text{C}$, povprečje telesne temperature žensk pa z $\hat{\mu}_2 = 98.39385^\circ\text{F} = 36.88547^\circ\text{C}$.

Oceniti moramo še standardni odklon telesnih temperatur, tako žensk kot moških. Na predavanjih smo povedali, da za cenilko standardnega odklona, ko vemo, da imamo opravka z normalno porazdelitvijo, vzamemo

$$\hat{\sigma} = \sqrt{\frac{1}{n-1} \sum_{i=1}^n (X_i - \hat{\mu})^2}.$$

Torej za naši cenilki standardnega odklona vzamemo

$$\hat{\sigma}_1 = \sqrt{\frac{1}{64} \sum_{i=1}^{65} (X_i - \hat{\mu}_1)^2}, \quad \hat{\sigma}_2 = \sqrt{\frac{1}{64} \sum_{i=1}^{65} (Y_i - \hat{\mu}_2)^2}.$$

Izračunamo, da je standardni odklon moških telesnih temperatur ocenjen z $\hat{\sigma}_1 = 0.69876\text{F} = 0.38820\text{C}$, ženskih pa z $\hat{\sigma}_2 = 0.74349\text{F} = 0.41305\text{C}$.

b)

Sedaj poizkusimo določiti intervale zaupanja za povprečji iz prejšnje točke. Izračunali bomo aproksimativni in eksaktni interval zaupanja. Na predavanjih smo povedali, da je aproksimativni interval zaupanja oblike

$$\left(\hat{\mu} - \widehat{SE}_+ \Phi^{-1}\left(1 - \frac{\alpha}{2}\right), \quad \hat{\mu} + \widehat{SE}_+ \Phi^{-1}\left(1 - \frac{\alpha}{2}\right) \right),$$

kjer je Φ^{-1} inverz kumulativne funkcije normalne porazdelitve, \widehat{SE} pa je srednja kvadratična napaka, definirana kot

$$\widehat{SE}_+ = \frac{\hat{\sigma}}{\sqrt{n}}.$$

Ker imamo opravka z 95% intervali zaupanja, bo stopnja tveganja enaka $\alpha = 0.05$. Aproksimativni interval zaupanja telesne temperature moških je tako enak $\hat{\mu}_1 \in (97.93475\text{F}, 98.27449\text{F}) = (36.63041\text{C}, 36.81916\text{C})$, pri ženskih telesnih temperaturah pa je enak $\hat{\mu}_2 \in (98.21310\text{F}, 98.57459\text{F}) = (36.78506\text{C}, 36.98588\text{C})$.

Eksaktni interval zaupanja je oblike

$$\left(\hat{\mu} - \widehat{SE}_+ \cdot F_{Student(n-1)}^{-1}\left(1 - \frac{\alpha}{2}\right), \quad \hat{\mu} + \widehat{SE}_+ \cdot F_{Student(n-1)}^{-1}\left(1 - \frac{\alpha}{2}\right) \right),$$

kjer je $F_{Student(n-1)}^{-1}$ inverz kumulativne funkcije studentove porazdelitve z $n - 1$ prostostnimi stopnjami.

Dobimo, da je eksaktni interval moških telesnih temperatur enak $\hat{\mu}_1 \in (97.93147\text{F}, 98.27776\text{F}) = (36.62860\text{C}, 36.82098\text{C})$, pri ženskih telesnih temperaturah pa je enak $\hat{\mu}_2 \in (98.20962\text{F}, 98.57807\text{F}) = (36.78312\text{C}, 36.98782\text{C})$.

c)

Preizkusite domnevo, da imajo moški in ženske v povprečju enako telesno temperaturo.

Sedaj bomo preizkusili domnevo, da imajo moški in ženske v povprečju enako telesno temperaturo. Za ničelno domnevo H_0 bomo vzeli $H_0 : \mu_1 = \mu_2$. Privzeli smo, da sta temperaturi pri moških in ženskah porazdeljeni normalno, torej je

$$\hat{\mu}_1 \sim N\left(\mu_1, \frac{\sigma_1^2}{65}\right) \quad \text{in} \quad \hat{\mu}_2 \sim N\left(\mu_2, \frac{\sigma_2^2}{65}\right)$$

Sledi, da je

$$\hat{\mu}_1 - \hat{\mu}_2 \sim N\left(\mu_1 - \mu_2, \frac{\sigma_1^2 + \sigma_2^2}{65}\right),$$

oziroma

$$\frac{(\hat{\mu}_1 - \hat{\mu}_2) - (\mu_1 - \mu_2)}{\sqrt{\frac{\sigma_1^2 + \sigma_2^2}{65}}} \sim N(0, 1).$$

Težava je v tem, da σ_1 in σ_2 ne poznamo, poznamo pa približka izračunana v prvi točki: $\hat{\sigma}_1$ $\hat{\sigma}_2$. Na predavanjih smo povedali, da lahko imenovalc zamenjamo s približkom $\sqrt{\frac{\hat{\sigma}_1^2 + \hat{\sigma}_2^2}{65}}$, vendar moramo normalno porazdelitev $N(0, 1)$ zamenjati s Studentovo porazdelitvijo z $n - 1$ prostostnimi stopnjami ($Student(n - 1)$). Tako imamo test T ;

$$T = \frac{(\hat{\mu}_1 - \hat{\mu}_2) - (\mu_1 - \mu_2)}{\sqrt{\frac{\hat{\sigma}_1^2 + \hat{\sigma}_2^2}{65}}} \sim Student(64)$$

Če upoštevamo ničelno domnevo $H_0 : \mu_1 = \mu_2$, je

$$T = \frac{(\hat{\mu}_1 - \hat{\mu}_2)}{\sqrt{\frac{\hat{\sigma}_1^2 + \hat{\sigma}_2^2}{65}}}.$$

Ker smo povprečji in standardna odklona ocenili že pri prvi točki, lahko izračunamo vrednost testa T :

$$T = -2.28543, \quad |T| = 2.28543.$$

Hipotezo bomo preverili pri stopnjah tveganja $\alpha = 0.05$ in $\alpha = 0.01$. Ničelno domnevo bomo zavrnili, če bo

$$|T| \geq F_{Student(64)}^{-1}\left(1 - \frac{\alpha}{2}\right).$$

Pri $\alpha = 0.05$ bomo imeli $|T| = 2.28543 \geq 1.99773$, tako da tu ničelno domnevo zavrnamo. Za $\alpha = 0.01$ pa dobimo, da je $|T| = 2.28543 < 2.65485$, torej tu domnevo sprejmemo. Ker iz meritev vidimo, da bo kvečjemu telesna temperatura žensk v povprečju višja od moških, bomo naredili še enostranski test. Ničelno domnevo bomo zavrnili, če bo

$$T \leq -F_{Student(64)}^{-1}(1 - \alpha) = F_{Student(64)}^{-1}(\alpha).$$

Za $\alpha = 0.05$ izračunamo, da je $T = -2.28543 \leq -1.66901$, torej ničelno domnevo zavrnamo. Pri $\alpha = 0.01$ dobimo, da je $T = -2.28543 > -2.38604$, tako da ničelno domnevo sprejmemo.

Tretja naloga

V datoteki Temp LJ se nahajajo izmerjene mesečne temperature v Ljubljani v letih od 1986 do 2020. Postavimo naslednja dva modela spreminjanja temperature s časom:

- Model A: vključuje linearni trend in sinusno nihanje s periodo eno leto.
- Model B: vključuje linearni trend in spreminjanje temperature za vsak mesec posebej.

Očitno je model B širši od modela A.

a)

Preizkusite model A znotraj modela B.

V datoteki Temp LJ smo dobili podatke o mesečnih temperaturah izmerjenih v Ljubljani od leta 1986 do leta 2020. Najprej si bomo za predstavo narisali graf iz danih podatkov:

Vidimo, da graf izgleda nekako tako, kot pravi model A: graf kot celota se z rahlim naklonom linearno dviga, zraven pa vsako leto graf 'sinusno' zaniha. Za vsako leto izračunajmo povprečno temperaturo in si pogledjmo, kako bo to izgledalo na grafu.

Vidimo, da se povprečne letne temperature gibljejo okoli neke premice, ki se z rahlim naklonom dviga. Po metodi najmanjših kvadratov izračunajmo, katera je premica, ki se najbolj prilega.

b)

Pri modeliranju je nevarno privzeti preširok model: lahko bi recimo postavili model, po katerem je temperatura vsak mesec drugačna, neidvisno od ostalih mesecev, a tak model bi bil neuporaben za napovedovanje. Akaikejeva informacija nam pomaga poiskati optimalni model – izberemo tistega, za katerega je le-ta najmanjša. Akaikejeva informacija je sicer definirana z verjetjem, a pri linearni regresiji in Gaussovem modelu je le-ta ekvivalentna naslednji modifikaciji:

$$\text{AIC} := 2m + n \ln \text{RSS},$$

kjer je m število parametrov, n pa je število opažanj. Kateri od zgornjih dveh modelov ima manjšo Akaikejevo informacijo?

Literatura